Álgebra Linear - PCA

Fernanda Rafaela

Novembro, 2024

1 Dataset

O dataset inclui fatores de risco que auxiliam na previsão e prevenção de doenças cardiovasculares, possibilitando a análise de elementos que influenciam a mortalidade por insuficiência cardíaca.

Link: https://www.kaggle.com/datasets/andrewmvd/heart-failure-clinical-data

2 Desenvolvimento

Para realizar a normalização dos dados e aplicar o algoritmo de PCA, serão usadas as seguintes bibliotecas no Python:

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
```

Figure 1: Bibliotecas utilizadas para análise

Primeiro, importamos o arquivo CSV e normalizamos o dataset, calculando a média de cada coluna e subtraindo do total:

Figure 2: Importação do CSV

Em seguida, calculamos a matriz de covariância, transpondo-a:

Figure 3: Matriz de Covariância

Agora, calculamos os autovetores e autovalores e ordenamos do maior para o menor:

Figure 4: Cálculo dos Autovalores e Autovetores

Maiores autovalores e autovetores:

Figure 5: Exibição dos maiores autovetores e autovalores

```
k = 2
pca = np.matmul(df_scaled, eigvectors[:,:k])

plt.figure(figsize=(8, 6))
sns.scatterplot(x=pca.iloc[:, 0], y=pca.iloc[:, 1])
plt.title('PCA: PC1 vs PC2')
plt.xlabel('Componente Principal 1')
plt.ylabel('Componente Principal 2')
plt.show()
```

Figure 6: Criação mapa 2d

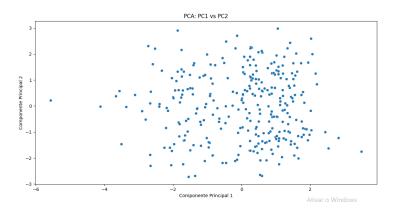


Figure 7: Mapa 2d

Usando os maiores 3 autovetores calculamos o p
ca e fazemos o gráfico tridimensional:

```
k = 3
pca = np.matmul(df_scaled, eigvectors[:,:k])

fig = plt.figure(figsize=(10, 8))
ax = fig.add_subplot(111, projection='3d')
ax.scatter(pca.iloc[:, 0], pca.iloc[:, 1], pca.iloc[:, 2])
ax.set_xlabel('Componente Principal 1')
ax.set_ylabel('Componente Principal 2')
ax.set_zlabel('Componente Principal 3')
plt.title('PCA: PC1 vs PC2 vs PC3')
plt.show()
```

Figure 8: Criação mapa 3d

PCA: PC1 vs PC2 vs PC3




Figure 9: Mapa 3d

repo: https://github.com/xfeehrxx/pca